



TOPKAPI ÜNİVERSİTESİ

BİLGİSAYAR

MÜHENDİSLİĞİ

**NEUROLUNG: DERİN ÖĞRENME TABANLI GÖĞÜS RÖNTGENİ ANALİZİ
VE COVID-19 TEŞHİS SİSTEMİ**

FET312 - DERİN ÖĞRENME DERSİ FİNAL PROJESİ

İSİM SOYİSİM: ECREN NAZLI KIRNAPCI

NUMARA: 23040101016

İSİM SOYİSİM: SELEN ERLER

NUMARA: 23040101027

İSİM SOYİSİM: SUDENAZ SUSAM

NUMARA: 23040101008

İSİM SOYİSİM: MEHMET EMİN SU

NUMARA: 23040101004

DERSİN ADI VE ÖĞRETİM ELEMANI: DERİN ÖĞRENME - YILDIZ KARADAYI

PROJE SUNUM VİDEOSU (YouTube): <https://youtu.be/Maz4kq9r-MA>

PROJE GİTHUB LİNKİ:

https://github.com/mehmeteminsu/FET312_NeuroLung_Project

GİRİŞ VE PROJE TANIMI

1. Proje Konusu ve Odaklanılan Problem

Bu proje, tüm dünyayı etkisi altına alan COVID-19 pandemisi ve benzeri akciğer enfeksiyonlarının (Viral Zatürre, Akciğer Opaklığı) teşhis sürecinde, yapay zeka ve derin öğrenme tekniklerinin kullanımını konu almaktadır. Tıbbi görüntüleme yöntemlerinden biri olan Göğüs Röntgeni (Chest X-Ray) analizleri, radyologlar için zaman alıcı ve yüksek dikkat gerektiren bir süreçtir.

Projenin odaklandığı temel problemler şunlardır:

- Hastalık teşhis süreçlerindeki insan kaynaklı hata payını minimize etmek.
- Sağlık sistemleri üzerindeki yoğunluğu azaltmak amacıyla hızlı bir ön tanı mekanizması geliştirmek.
- Röntgen görüntülerindeki çıplak gözle fark edilmesi zor olan patolojik dokuları, derin öğrenme algoritmalarıyla yüksek doğrulukta tespit etmek.

2. Projenin Amacı ve Hedefleri

Projenin temel amacı, farklı derin öğrenme mimarilerinin (ResNet, VGG, DenseNet, MobileNet vb.) akciğer hastalıklarını sınıflandırma performanslarını bilimsel bir perspektifle karşılaştırmaktır.

Bu doğrultuda belirlenen spesifik hedefler:

- **Çok Sınıflı Sınıflandırma:** Görüntüleri "Normal", "COVID-19", "Lung Opacity" ve "Viral Pneumonia" olmak üzere 4 farklı kategoriye doğru şekilde ayırmak.
- **Transfer Learning Uygulaması:** Önceden eğitilmiş (pretrained) modeller kullanarak kısıtlı zamanda maksimum başarıya ulaşmak.
- **Model Optimizasyonu:** Temel (Base) modelleri, hiperparametre ayarlamaları (Dropout, ek katmanlar, öğrenme oranı optimizasyonu) ile geliştirerek daha güvenilir teşhis sonuçları elde etmek.

- **Karşılaştırmalı Analiz:** Hafif ve hızlı modeller (MobileNet, SqueezeNet) ile derin ve karmaşık modellerin (ResNet50, VGG19) tıbbi teşhis alanındaki verimlilik farklarını ortaya koymak.

3. Çözüm Yaklaşımı

Projede "NeuroLung" ismi verilen bir yapı altında, evrişimli sinir ağları (CNN) temelli 8 farklı model varyasyonu test edilmiştir. Görüntü işleme teknikleri (Data Augmentation) kullanılarak veri seti çeşitlendirilmiş ve modellerin ezberlemesinin önüne geçilmiştir. Sonuçlar; doğruluk, kesinlik, duyarlılık ve F1-skor gibi metrikler üzerinden analiz edilerek en optimum çözüm yolu belirlenmiştir.

KULLANILAN VERİ SETİ VE AÇIKLAMASI

Kaynak: Projede kullanılan veri seti, Katar Üniversitesi ve Dakka Üniversitesi'nden araştırmacıların iş birliğiyle oluşturulan, "**COVID-19 Radiography Database**" isimli ödüllü veri setidir.

- **Kaynak Linki:** [Kaggle - COVID-19 Radiography Database](https://www.kaggle.com/paultatkin/COVID-19-Radiography-Dataset)

a. Veri Setinin Boyutu

Veri seti, göğüs röntgeni (X-ray) görüntülerinden oluşan kapsamlı bir koleksiyondur. Toplamda **21.165 adet görüntü** içermektedir. Görüntüler yüksek çözünürlüklü olup, model eğitimi sırasında 224×224 boyutlarına indirgenerek işlenmiştir.

b. Sınıflandırma ve Dağılım (Label Count)

Bu projede 4 farklı sınıf (label) üzerinde odaklanılmıştır. Veri setindeki dağılım şu şekildedir:

Sınıf Etiketi	Görüntü Sayısı	Açıklama
COVID-1G	3.616	COVID-19 pozitif akciğerler.
Normal	10.192	Herhangi bir hastalık bulgusu olmayanlar.
Lung Opacity	6.012	COVID dışı akciğer opaklığı (enfeksiyon vb.).
Viral Pneumonia	1.345	Viral zatürre vakaları.
TOPLAM	21.165	

Not: Veri setinde "Normal" sınıfı en yoğun, "Viral Pneumonia" sınıfı ise en az veriye sahip sınıftır. Bu dengesizliği (imbalance) yönetmek için model eğitiminde veri artırımı (augmentation) teknikleri kullanılmıştır.

c. Train-Test Split (Veri Bölümleme)



Modelin eğitim performansını ve gerçek dünya verilerine karşı genellebilirliğini (generalization) ölçmek adına veri seti üç temel parçaya bölünmüştür:

- Eğitim Seti (Training Set - %70):** Modelin ağırlıklarını güncellediği, hastalık belirtilerini (opaklık, buzlu cam manzarası vb.) öğrenmek için kullandığı ana veri grubudur.
- Doğrulama Seti (Validation Set - %15):** Eğitim devam ederken modelin performansını "tarafsız" bir şekilde kontrol etmek için kullanılır. Hiperparametre optimizasyonu (öğrenme oranı, dönem sayısı gibi) bu setten gelen geri bildirimlere göre takip edilir.
- Test Seti (Test Set - %15):** Modelin eğitim süreci tamamen bittikten sonra, doğruluğunu nihai olarak test etmek için kullanılan "hiç görülmemiş" verilerdir.

Stratified (Tabakalı) Bölümleme Mantığı: Veri setimizde sınıflar arası sayısal bir dengesizlik (Örneğin: 10.192 Normal vakasına karşılık 1.345 Viral Pneumonia vakası) bulunmaktadır. Bu durumun eğitimi bozmaması için bölümleme işlemi "**Stratified**" (tabakalı) yöntemle yapılmıştır. Bu yöntem sayesinde, her bir veri kümesindeki (eğitim, doğrulama, test) hastalık sınıflarının oranı, orijinal veri setindeki oranla birebir aynı tutulur. Böylece modelin azınlıkta kalan sınıfları (Viral Pneumonia gibi) göz ardı etmesi engellenmiş ve her sınıftan yeterli örnek görmesi sağlanmıştır.

Eğer standart 'Rastgele Bölümleme' (Random Split) kullanılsaydı, sayıca az olan Viral Pneumonia örneklerinin şans eseri çoğunlukla Test veya Doğrulama setine yığılması ve Eğitim setinde yetersiz kalması riski doğacaktı.

Stratified yöntem sayesinde, her bir veri kümesindeki (Eğitim, Doğrulama, Test) hastalık sınıflarının oranı, orijinal veri setindeki oranla birebir aynı tutulmuştur. Bu işlem sonucunda veri seti %70 Eğitim, %15 Doğrulama ve %15 Test oranlarıyla bölünmüş, böylece modelin azınlıkta kalan sınıfları göz ardı etmesi engellenmiş ve her sınıftan dengeli örnek görmesi garanti altına alınmıştır.







Model Mimarileri ve Hiperparametre Analizi

Bu bölümde, her grup üyesinin seçtiği başlangıç (Base) modelleri ile bu modelleri iyileştirerek oluşturdukları ileri (Advanced) modellerin teknik detayları ve optimizasyon süreçleri açıklanmıştır. Tüm modellerde ortak olarak 224×224 görüntü boyutu ve **Adam Optimizer** (lr=0.0003) kullanılmıştır.

A. Mehmet'in Analizi: Klasik vs. Derin Rezidüel Yapı

- **Base Model (AlexNet):** 2012'de derin öğrenmeyi başlatan bu mimari, hızlı bir başlangıç noktası olarak seçilmiştir. Son katman doğrudan 4 sınıfa yönlendirilmiştir.
- **Advanced Model (ResNet50):** AlexNet'in basit yapısı, 50 katmanlı ve "Skip Connection" (Atlama Bağlantısı) içeren ResNet50 ile değiştirilmiştir.
- **Tuning ve Optimizasyon:** Modelin derinliği arttığı için ezberlemeyi önlemek amacıyla sınıflandırıcı kısmına **0.4 Dropout** ve 512 nöronluk ek bir **ReLU** katmanı eklenerek öğrenme kapasitesi artırılmıştır.







B. Ecren'in Analizi: Ölçeklenebilir ve Verimli Mimari (EfficientNet)

- **Base Model (VGG11_BN):** Küçük 3×3 evrişimli filtreler kullanarak derinliği artıran VGG ailesinin temel üyesidir. Eğitim sürecinin daha kararlı (stabil) ilerlemesi ve daha hızlı yakınsama sağlanması amacıyla "Batch Normalization" (BN) katmanlarını içeren versiyon tercih edilmiştir.
- **Advanced Model (EfficientNet-B0):** Derin öğrenme literatüründe "Compound Scaling" (Bileşik Ölçeklendirme) yöntemiyle bilinen, hem işlem gücü hem de yüksek doğruluk açısından optimize edilmiş bir mimaridir. Bu model; ağın derinliğini, genişliğini ve giriş görüntüsü çözünürlüğünü aynı anda dengeleyerek göğüs röntgenlerindeki karmaşık patolojik dokuları tespit etmek üzere yapılandırılmıştır.
- **Tuning ve Optimizasyon:**
 - **Özel Sınıflandırıcı (Custom Classifier):** EfficientNet-B0'ın 1280 kanallık özellik çıkarım katmanı, projedeki 4 ana sınıfa

(COVID, Normal, Lung Opacity, Viral Pneumonia) yanıt verecek şekilde güncellenmiştir.





- **Dropout Stratejisi:** Modelin son katmanında **0.2 Dropout** uygulanarak, özellikle kısıtlı veriye sahip "Viral Pneumonia" gibi sınıflarda modelin ezberlemesi (overfitting) engellenmiştir.
- **Aktarımlı Öğrenme:** ImageNet üzerinde önceden eğitilmiş ağırlıklar kullanılarak, modelin genel görsel özellikleri (kenarlar, dokular, gölgeler) başlangıçtan itibaren tanınması sağlanmıştır.



C. Selen'in Analizi: Standart Derinlik vs. Yoğun Bağlantılar





- **Base Model (ResNet18):** Performans ve hız dengesi nedeniyle "Altın Standart" olarak kabul edilen 18 katmanlı rezidüel ağıdır.
- **Advanced Model (DenseNet121):** Her katmanın birbirine bağlı olduğu bu model, ResNet'e göre daha az parametreyle daha zengin özellik çıkarımı yapar.

- **Tuning ve Optimizasyon:** DenseNet'in karmaşık yapısını korumak adına, hiperparametre optimizasyonu doğrudan çıkış katmanındaki doğrusal dönüşüm üzerine yoğunlaştırılmıştır.



D. Sude'nin Analizi: Hafif ve Mobil Mimariler

- **Base Model (SqueezeNet):** Çok düşük parametre sayısı ile AlexNet başarısı sunan, kaynak tasarruflu bir modeldir. Sınıflandırıcı kısmında klasik katman yerine 1×1 evrişimli (Conv2d) bir yapı kullanılmıştır.
- **Advanced Model (MobileNetV2):** SqueezeNet'ten daha yeni bir teknoloji olan "Inverted Residuals" mimarisi kullanılmıştır.
- **Tuning ve Optimizasyon:** Sınıflandırıcı katmanı 1280 kanaldan 4 sınıfa indirgenirken, Adam optimizator'ın momentum değerleri modelin hızına uyum sağlayacak şekilde optimize edilmiştir.



Hiperparametre Özet Tablosu

Parametre	Base Modeller	Advanced Modeller (Ortalama)	Neden Bu Seçildi?
Learning Rate	0.0003	0.0003	Gradyanların kararlı bir şekilde azalması için en stabil değerdir.
Dropout	Yok	0.4 - 0.5	Derin modellerde (VGG19, ResNet50) ezberlemeyi (overfitting) önlemek için.
Batch Size	32	32	Colab GPU belleği (T4) için en verimli yığın boyutu.
Hidden Units	-	512 / 1024	Görüntüden gelen soyut özellikleri sınıflandırmadan önce işlemek için.

Performans Karşılaştırması ve Metrik Analizi

Modellerin başarısını ölçmek için sadece "Accuracy" (Doğruluk) metriği yeterli değildir; özellikle tıbbi teşhislerde hatalı negatif (hastayı sağlıklı sanma) ve hatalı pozitif (sağlıklıya hasta deme) oranları hayati önem taşır. Bu nedenle şu metrikler kullanılmıştır:

- **Accuracy (Doğruluk):** Genel başarı oranı.
- **Precision (Kesinlik):** Modelin "Hasta" dediği kişilerin kaçısı gerçekten hastadır?
- **Recall (Duyarlılık):** Gerçekten hasta olanların kaçısı model tarafından yakalanabilmiştir?
- **F1-Score:** Kesinlik ve Duyarlılığın dengeli bir ortalamasıdır.

a. Tablo 1: Genel Model Karşılaştırması (Test Verisi)

Bu tabloda, modellerin test setindeki genel performansları yer almaktadır.

Model	Accuracy (%)	Precision (Macro Avg)	Recall (Macro Avg)	F1-Score (Macro Avg)
AlexNet (Mehmet - Base)	%84.25	0.85	0.81	0.82
ResNet50 (Mehmet - Adv)	%86.31	0.87	0.85	0.85
VGG11_BN (Ecren - Base)	%85.45	0.89	0.82	0.84
EfficientNet-B0 (Ecren - Adv)	%87.01	0.90	0.83	0.86
ResNet18 (Selen - Base)	%85.73	0.88	0.82	0.85
DenseNet121 (Selen - Adv)	%84.69	0.83	0.83	0.83
SqueezeNet (Sude - Base)	%84.17	0.84	0.80	0.82
MobileNetV2 (Sude - Adv)	%86.94	0.87	0.85	0.86

b. Tablo 2: Sınıf Bazlı Başarım Karşılaştırması (F1-Score)

Bu tabloda, modellerin her bir hastalık kategorisinde ne kadar başarılı olduğu gösterilmektedir. Değerler olarak her sınıfın **F1-Score** değeri baz alınmıştır (Çünkü F1-score, sınıflar arasındaki sayısal dengesizliği en iyi yansıtan metriktir).

Model	COVID-19	Normal	Lung Opacity	Viral Pneumonia
AlexNet (Base)	0.72	0.88	0.80	0.89
ResNet50 (Adv)	0.78	0.89	0.84	0.91
VGG11_BN (Base)	0.74	0.89	0.83	0.92
EfficientNet-B0 (Adv)	0.78	0.90	0.85	0.90
ResNet18 (Base)	0.76	0.88	0.82	0.92
DenseNet121 (Adv)	0.73	0.87	0.80	0.92
SqueezeNet (Base)	0.70	0.88	0.79	0.89
MobileNetV2 (Adv)	0.78	0.90	0.84	0.91

En İyi Modelin Seçimi ve Değerlendirme

Tüm metrikler ve sınıf bazlı analizler sonucunda projenin en başarılı modeli **EfficientNet-B0 (Ecren - Advanced)** olarak belirlenmiştir.

Neden EfficientNet-B0?


- Genel Başarı:** Model, **%87.01** doğruluk (accuracy) ve **0.90** kesinlik (precision) değerleriyle diğer tüm modelleri geride bırakmıştır. Özellikle tıbbi teşhislerde "yanlış alarm" vermemek (Precision) sistemin güvenilirliği açısından kritiktir.
- Kritik Sınıflardaki Üstünlük:** Teşhis edilmesi en zor olan **COVID-19** sınıfında **0.78** ve **Lung Opacity** sınıfında **0.85** F1-skoru ile en yüksek performansı sergilemiştir. Bu durum, EfficientNet'in "Compound Scaling" yapısının akciğerdeki mikro doku bozulmalarını yakalamada ne kadar etkili olduğunu kanıtlamaktadır.

3. **Modern Mimari Avantajı:** ResNet50 ve MobileNetV2 modelleri de oldukça yakın sonuçlar verse de, EfficientNet-B0 hem daha hafif bir yapıda olması hem de parametre verimliliği sayesinde daha "kararlı" bir öğrenme sergilemiştir.
4. **Denge:** Model sadece en yaygın olan "Normal" sınıfında değil, aynı zamanda verisi daha az olan patolojik sınıflarda da dengeli bir başarı göstererek, veri setindeki dengesizliğe (imbalance) karşı en dirençli yapı olduğunu ispatlamıştır.

Son Not: MobileNetV2 modeli de benzer doğruluk oranlarına ulaşmıştır; ancak EfficientNet'in "Lung Opacity" (Akciğer Opasitesi) sınıfındaki net üstünlüğü, tıbbi radyoloji uygulamaları için onu bir adım öne çıkarmaktadır.

DENEYSEL SONUÇLAR

Ecren'in Modeli (VGG19) Tahmin Örnekleri



Görsel Tahmin Analizi

Modelin sayısal başarısını görsel olarak da doğrulamak adına, Test setinden rastgele seçilen örnekler üzerinde modelin tahminleri incelenmiştir (Bkz. Şekil 4).

- **Yeşil Etiketler:** Modelin tahmininin, gerçek etiketle (Ground Truth) eşleştiği başarılı durumları gösterir.
- **Kırmızı Etiketler:** Modelin hatalı tahmin yaptığı durumları gösterir.

Yapılan görsel analizde; modelin özellikle radyolojik olarak birbirine çok benzeyen **COVID-19** ve **Viral Pneumonia** vakalarını ayırt etmede yüksek başarı gösterdiği, hatalı tahminlerin (Kırmızı) ise genellikle görüntünün çok düşük kontrastlı olduğu veya akciğer opaklığının belirsiz olduğu nadir durumlarda gerçekleştiği gözlemlenmiştir. Bu durum, modelimizin sadece ezberlemediğini, hastalık özniteliklerini görsel olarak öğrendiğini kanıtlamaktadır.

ÖÇRENİLENLER VE SONUÇ

Bu proje süreci, ekip üyeleri olarak derin öğrenme ve tıbbi görüntüleme analizi konularında önemli teknik ve pratik kazanımlar elde etmemizi sağlamıştır:

- **Mimari Seçiminin Önemi:** Proje başında daha derin modellerin (VGG19 gibi) her zaman en iyi sonucu vereceği varsayılsa da; deneyler sonucunda **EfficientNet** gibi akıllı ölçeklendirme yapan modern mimarilerin, hem parametre verimliliği hem de doğruluk açısından çok daha üstün olduğunu deneyimledik.
- **Veri Dengesizliğiyle Mücadele:** Tıbbi veri setlerinde sınıfların (hastalık türlerinin) sayısal olarak eşit dağılmadığını gördük. Bu durumun eğitimi bozmaması için kullanılan **veri artırımı (Data Augmentation)** ve **Tabakalı Bölümleme (Stratified Splitting)** tekniklerinin, modelin nadir vakaları (Viral Pneumonia gibi) doğru teşhis etmesindeki kritik rolünü kavradık.
- **Hiperparametre Optimizasyonu:** Öğrenme oranı (learning rate) ve Dropout gibi parametrelerin en küçük değişimlerinin dahi modelin kararlılığını nasıl etkilediğini gözlemledik. Özellikle tıbbi teşhislerde

"yanlış negatif" oranını düşürmek için metrik analizinin (Precision vs Recall) önemini anladık.

- **Transfer Learning Gücü:** Milyonlarca görüntüyle önceden eğitilmiş ağırlıkları kullanmanın, kısıtlı bir veri setiyle dahi ne kadar hızlı ve başarılı sonuçlar üretebileceğini uygulamalı olarak gördük.
- **Ekip Çalışması ve Multi-Model Yaklaşım:** 8 farklı modeli eş zamanlı olarak test ederek, farklı mimari yaklaşımların güçlü ve zayıf yönlerini kıyaslama ve sonuçları bilimsel bir tabloda sentezleme becerisi kazandık.

KAYNAKÇA

Raporun hazırlanmasında ve modellerin teorik altyapısının oluşturulmasında aşağıdaki kaynaklardan yararlanılmıştır:

- Veri Seti Kaynağı:** Rahman, T., Khandakar, A., Qiblawey, Y., Tahir, A., Kiranyaz, S., Kashem, S. B. A., Islam, M. T., Al Maadeed, S., Zughaier, S. M., Khan, M. S., C Chowdhury, M. E. H. (2021). "Exploring the expectations of healthcare professionals from AI-based chest X-ray diagnosis." *IEEE Access*, 9, 75863-75874.
a. Not: Bu kaynak, kullandığınız COVID-1S Radiography Database'in resmi yayın noktasıdır.
- EfficientNet Mimarisi:** Tan, M., C Le, Q. V. (2019). "EfficientNet: Rethinking model scaling for convolutional neural networks." *International Conference on Machine Learning (ICML)*.
a. Not: Ecren'in seçtiği gelişmiş modelin temelini atan bilimsel makaledir.
- ResNet (Rezidüel Ağlar) Teorisi:** He, K., Zhang, X., Ren, S., C Sun, J. (2016). "Deep residual learning for image recognition." *Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR)*, 770-778.
a. Not: Mehmet ve Selen'in kullandığı ResNet mimarilerinin teknik altyapısını açıklar.
- DenseNet Mimarisi:** Huang, G., Liu, Z., Van Der Maaten, L., C Weinberger, K. Q. (2017). "Densely connected convolutional networks." *Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR)*, 4700-4708.
a. Not: Selen'in gelişmiş modelinin teorik çerçevesidir.
- Tıbbi Görüntüleme ve Transfer Learning:** Chowdhury, M. E., Rahman, T., Khandakar, A., Mazhar, R., Kadir, M. A., Mahbub, Z. B., ... C Al Maadeed, S. (2020). "Can AI help in screening Viral and COVID-19 pneumonia?" *IEEE Access*, 8, 132665-132676.
a. Not: Projede çözölen probleme (Zatürre ve COVIDteşhisi) odaklanan kapsamlı bir makaledir.

