

DERİN ÖĞRENME TABANLI COVID-19 VE ZATÜRRE TEŞHİS SİSTEMİ

Akciğer X-Ray görüntülerinden solunum yolu hastalıklarını sınıflandıran, temel ve modern CNN mimarilerinin performanslarını 'Base vs. Advanced' yaklaşımıyla inceleyen kapsamlı bir analiz

GRUP ADI: NEURO-LUNG

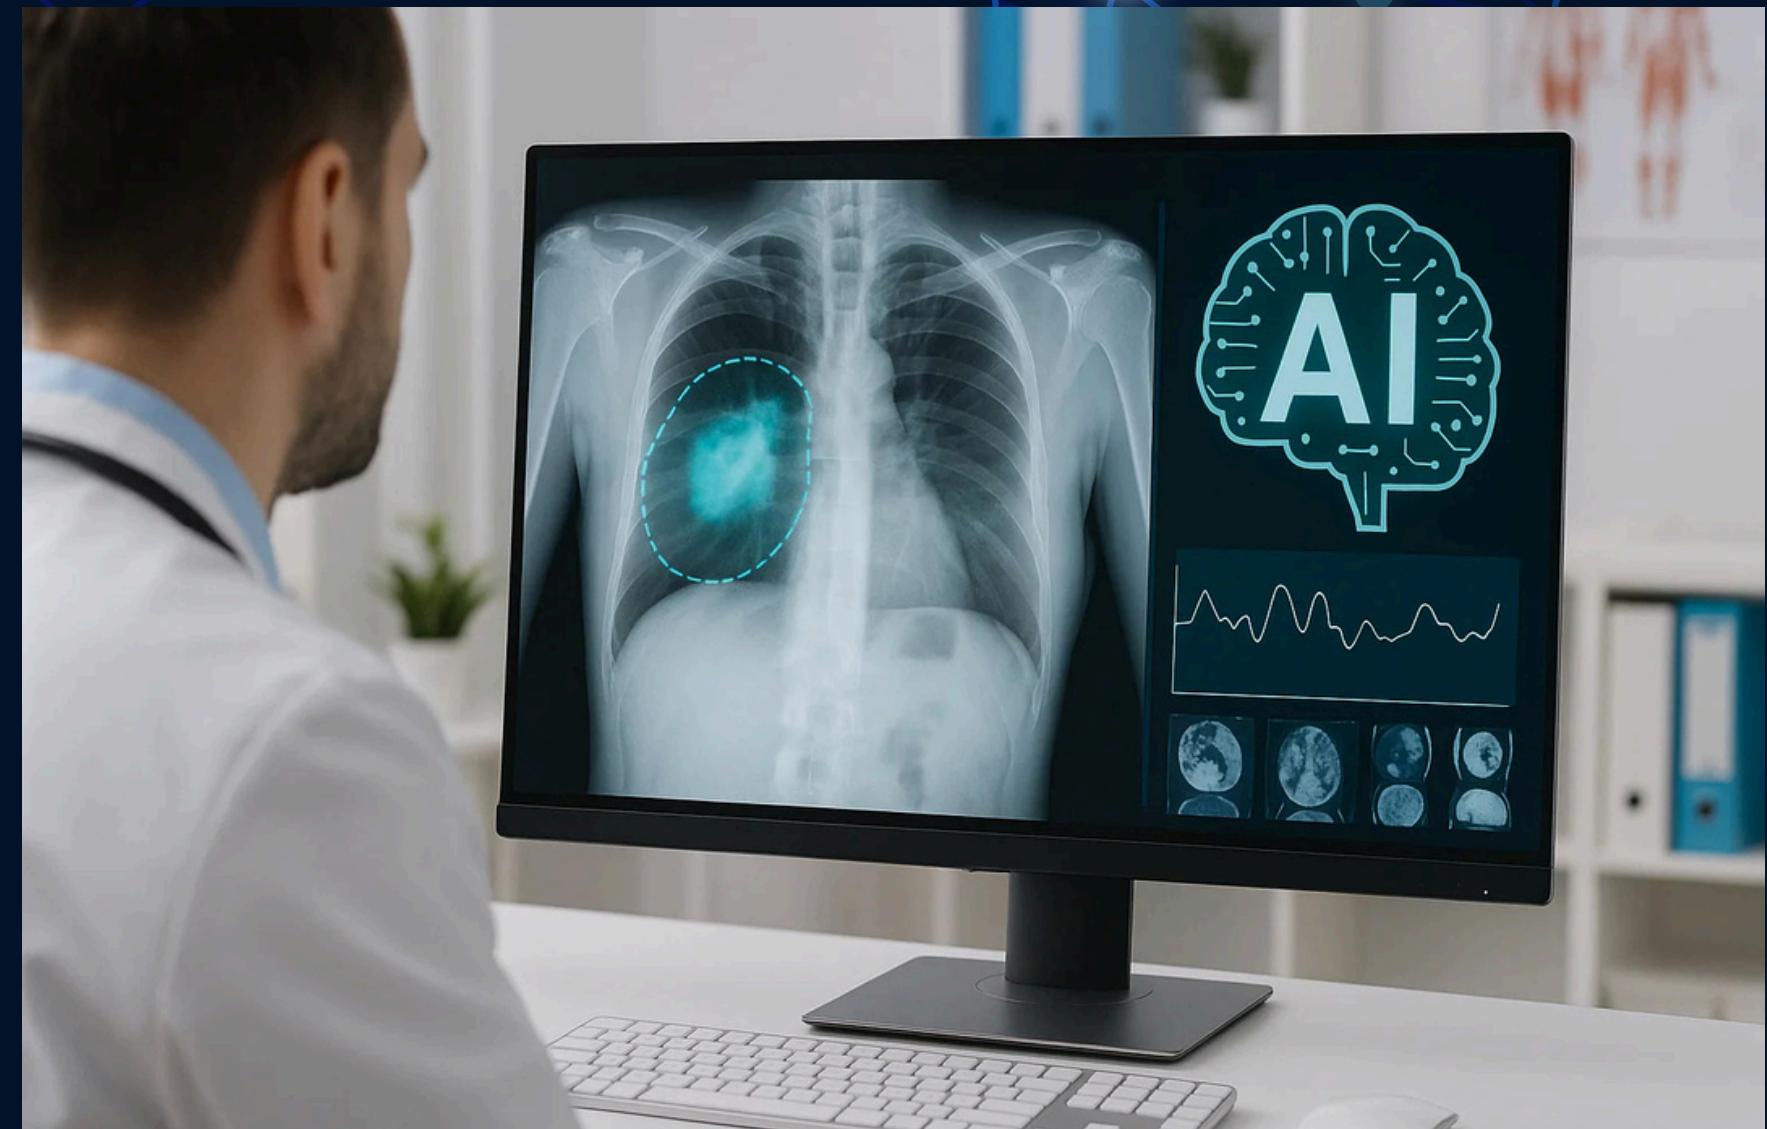
MEHMET EMIN SU : 23040101004
ECREN NAZLI KIRNAPCI : 23040101016
SELEN ERLER : 23040101027
SUDENAZ SUSAM : 23040101008



GİTHUB LINKİ: [HTTPS://GITHUB.COM/MEHMETEMINSU/FET312_NEUROLUNG_PROJECT](https://github.com/MEHMETEMINSU/FET312_NEUROLUNG_PROJECT)
YOUTUBE LINKİ: [HTTPS://YOUTU.BE/MAZ4KQ9R-MA](https://youtu.be/MAZ4KQ9R-MA)

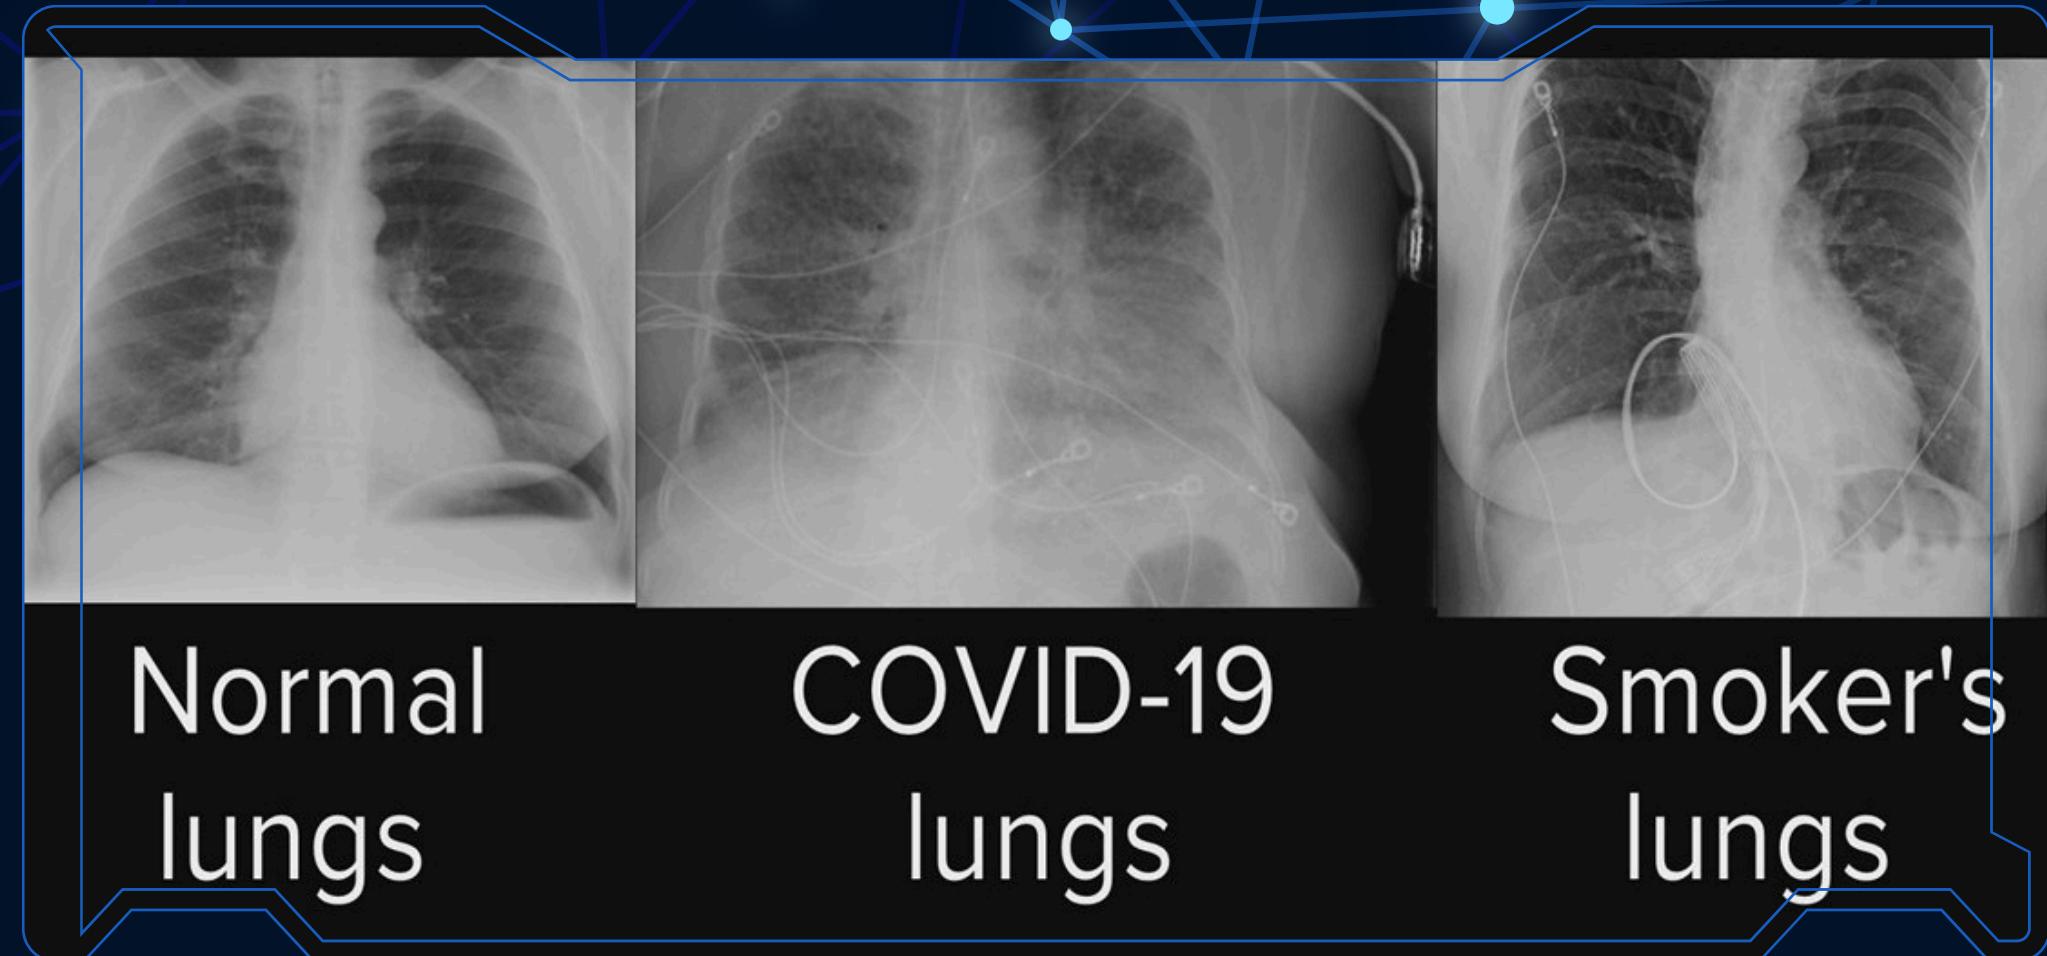
SUNUM İÇERİĞİ

- 1. PROBLEM TANIMI VE AMACIMIZ**
- 2. VERİ SETİ VE ÖN İŞLEME**
- 3. METODOLOJİ: BASE VS. ADVANCED MODELLER**
- 4. DENEYSEL SONUÇLAR VE KARŞILAŞTIRMA**
- 5. DEMO VE GÖRSEL TAHMİNLER**
- 6. SONUÇ VE KAZANIMLAR**



PROBLEM TANIMI VE ÇÖZÜM

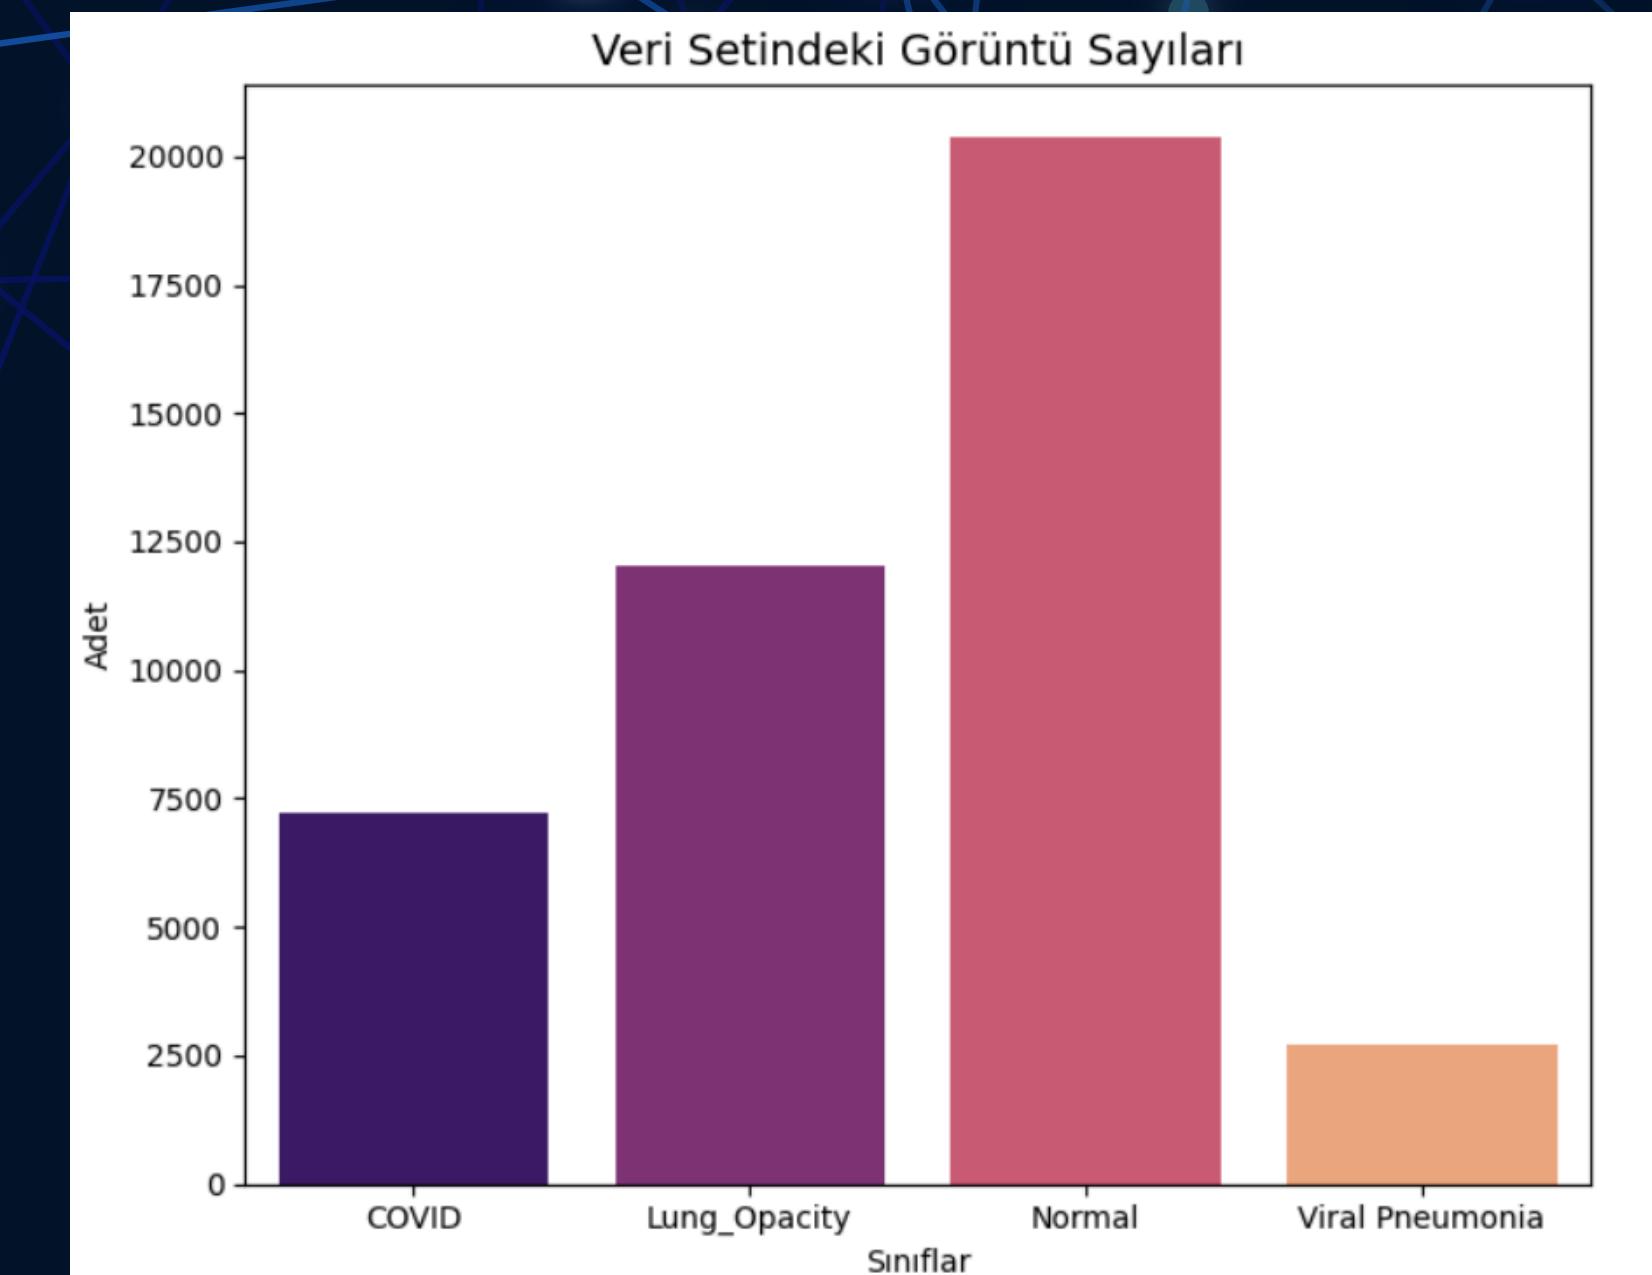
COVID-19 pandemisi ve solunum yolu hastalıkları, sağlık sistemleri üzerinde benzeri görülmemiş bir yoğunluk oluşturmuştur. Radyologların her gün binlerce göğüs röntgenini (X-Ray) manuel olarak incelemesi; hem ciddi bir zaman kaybına hem de yorgunluğa bağlı insan hatasına (human error) açık bir zemin hazırlamaktadır.



Veri Kaynağı ve Yapısal Analiz: COVID-19 Radyografi Veri Seti

Veri Kaynağı ve Kapsam

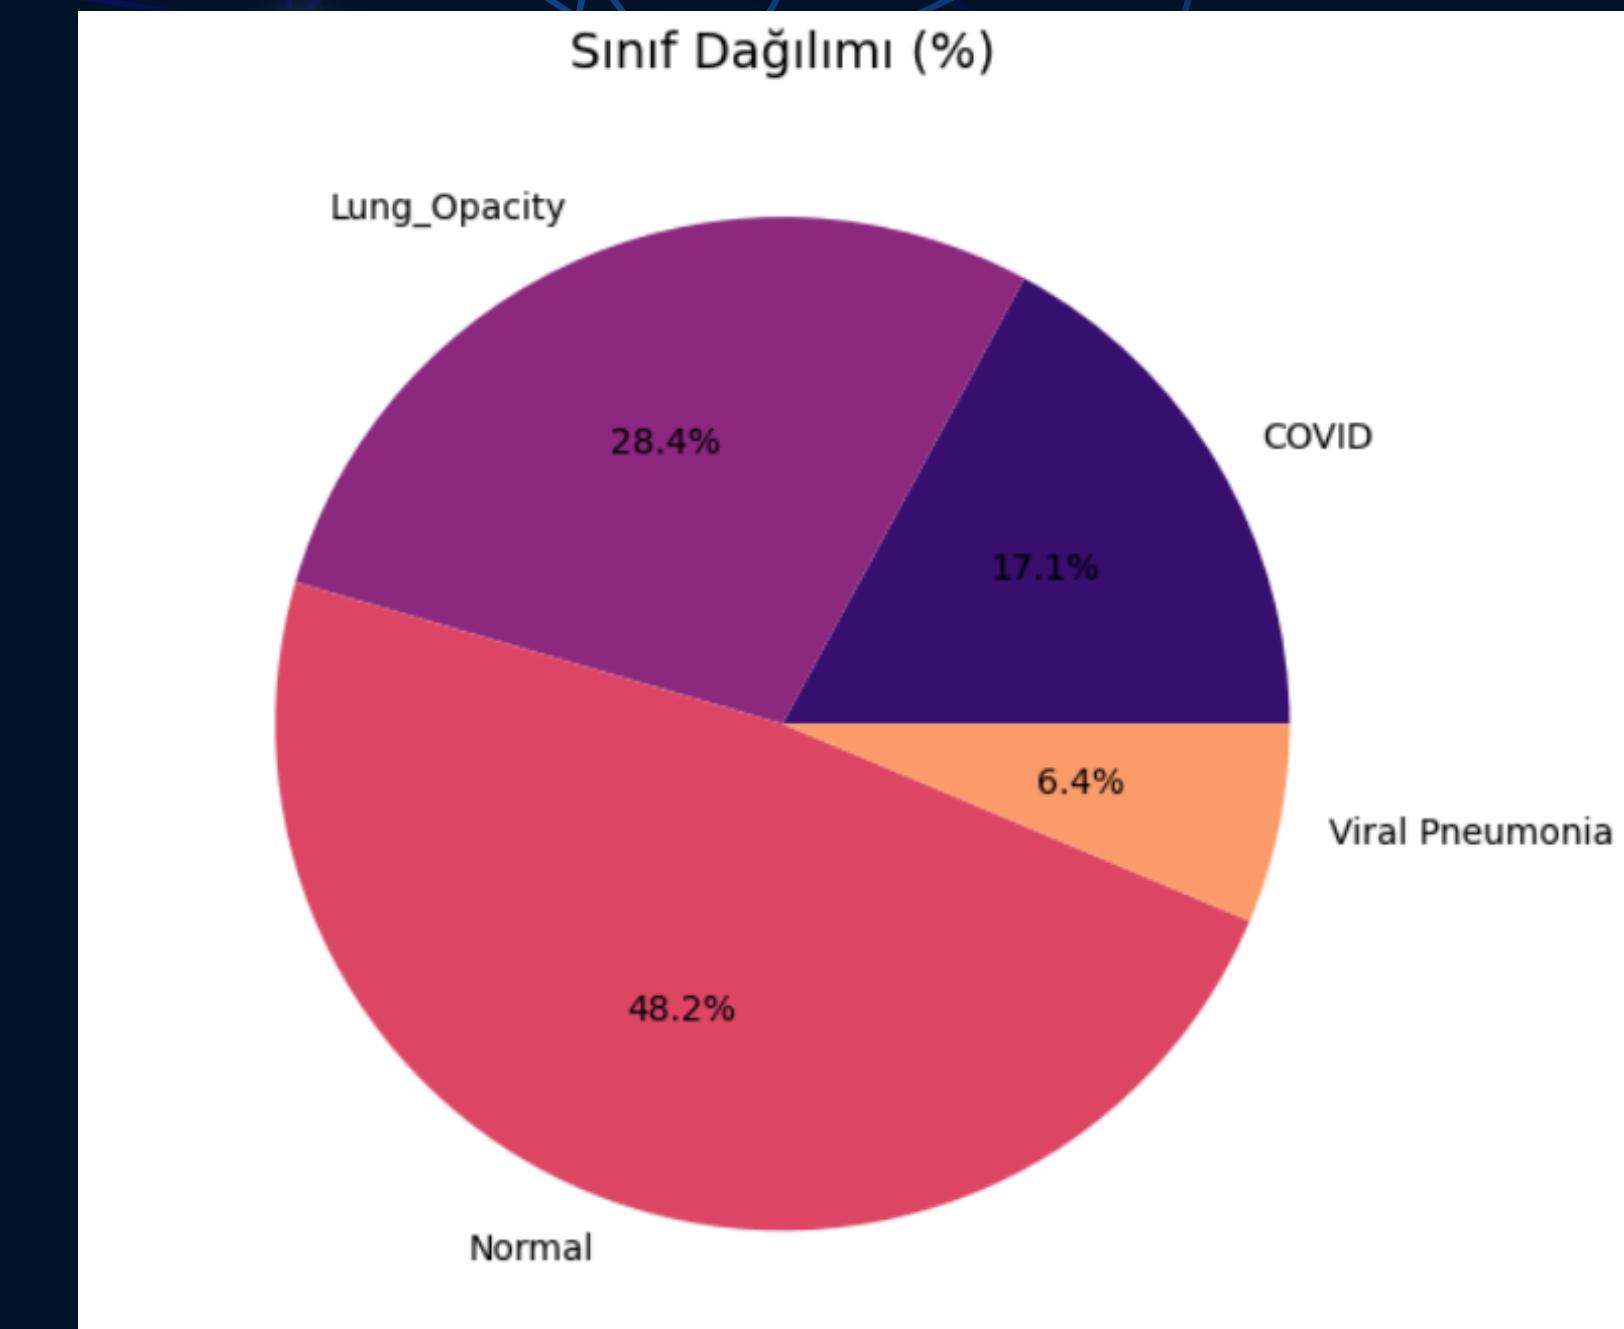
Çalışmamızın temelini, akademik araştırmalarda güvenilirliği kanıtlanmış olan Kaggle COVID-19 Radiography Database oluşturmaktadır. Toplamda 21.165 adet yüksek çözünürlüklü göğüs röntgeninden oluşan bu geniş veri seti; COVID-19, Viral Zatürre (Viral Pneumonia), Akciğer Opaklısı (Lung Opacity) ve Normal olmak üzere 4 temel klinik durumu kapsamaktadır.



Veri Kaynağı ve Yapısal Analiz: COVID-19 Radyografi Veri Seti

Yapısal Zorluk ve Çözüm

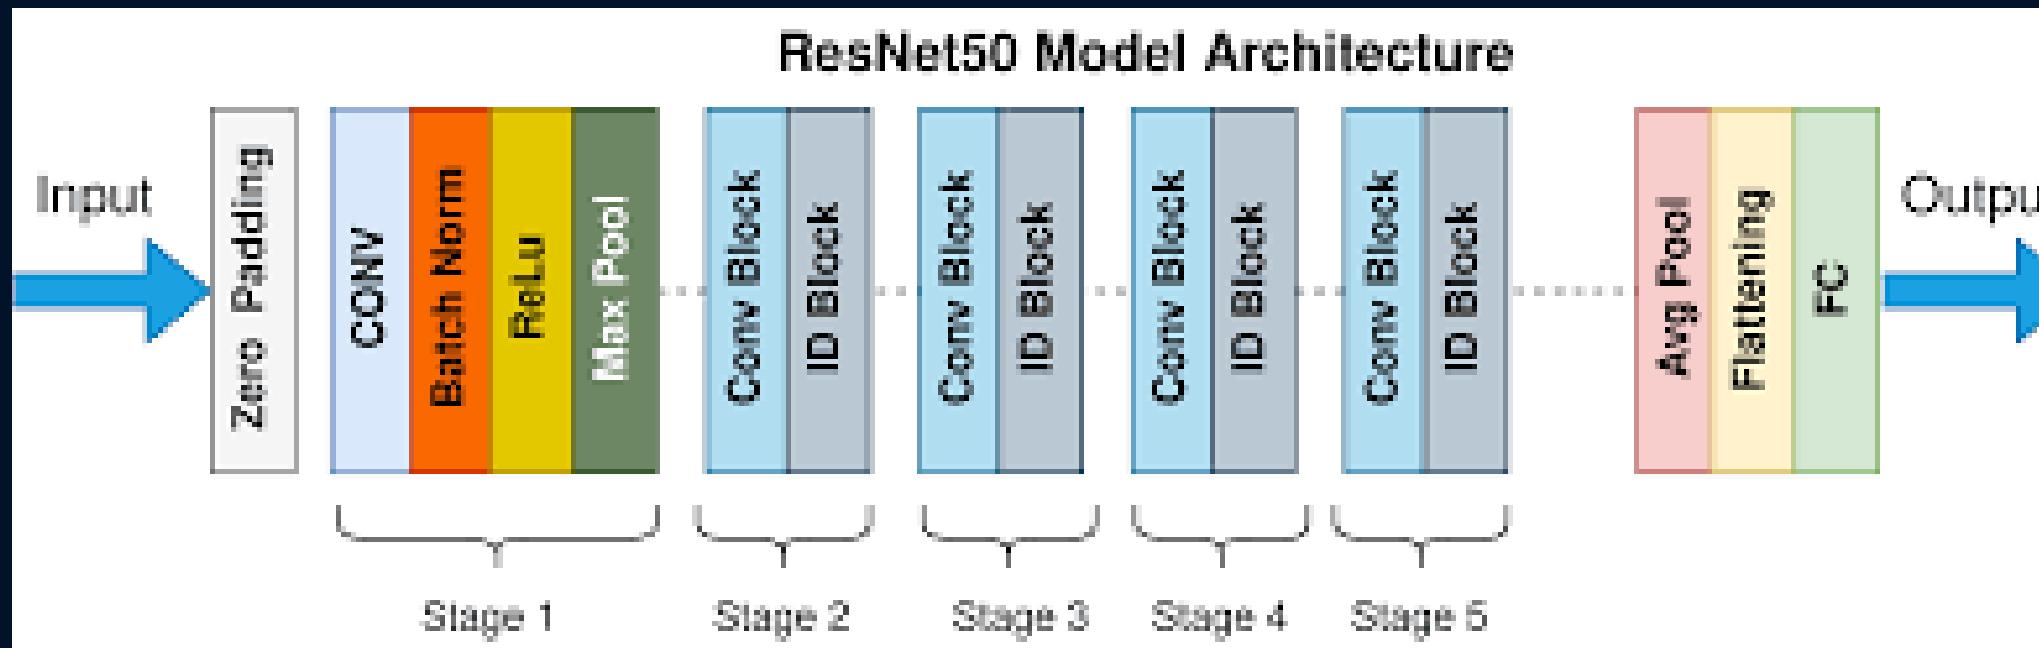
VERİ ÖN İŞLEME AŞAMASINDA KARŞILAŞTIĞIMIZ EN KRITİK ZORLUK, SINIFLAR ARASINDAKI VERİ DENGESİZLİĞİ (DATA IMBALANCE) OLMUŞTUR. GRAFIKTE DE GÖRÜLDÜĞÜ ÜZERE, 'NORMAL' VAKALAR VERİ SETİNİN BÜYÜK BİR KİSMINI OLUŞTURURKEN (10.000+), 'VIRAL ZATÜRRE' VAKALARI (1.345) SAYISAL OLARAK AZINLIKTADIR. MODELİN ÇOĞUNLUK SINIFI EZBERLEMESİSİNİ ÖNLEMEK VE NADIR GÖRÜLEN VAKALARI DA DOĞRU ÖĞRENMESİNİ SAĞLAMAK ADINA, EĞİTIM SETİNDE TABAKALI BÖLÜMLEME (STRATIFIED SPLIT) VE VERİ ARTIRMA TEKNİKLERİ TITİZLİKLE UYGULANMIŞTIR



Model Stratejimiz: Basitten Karmaşağa

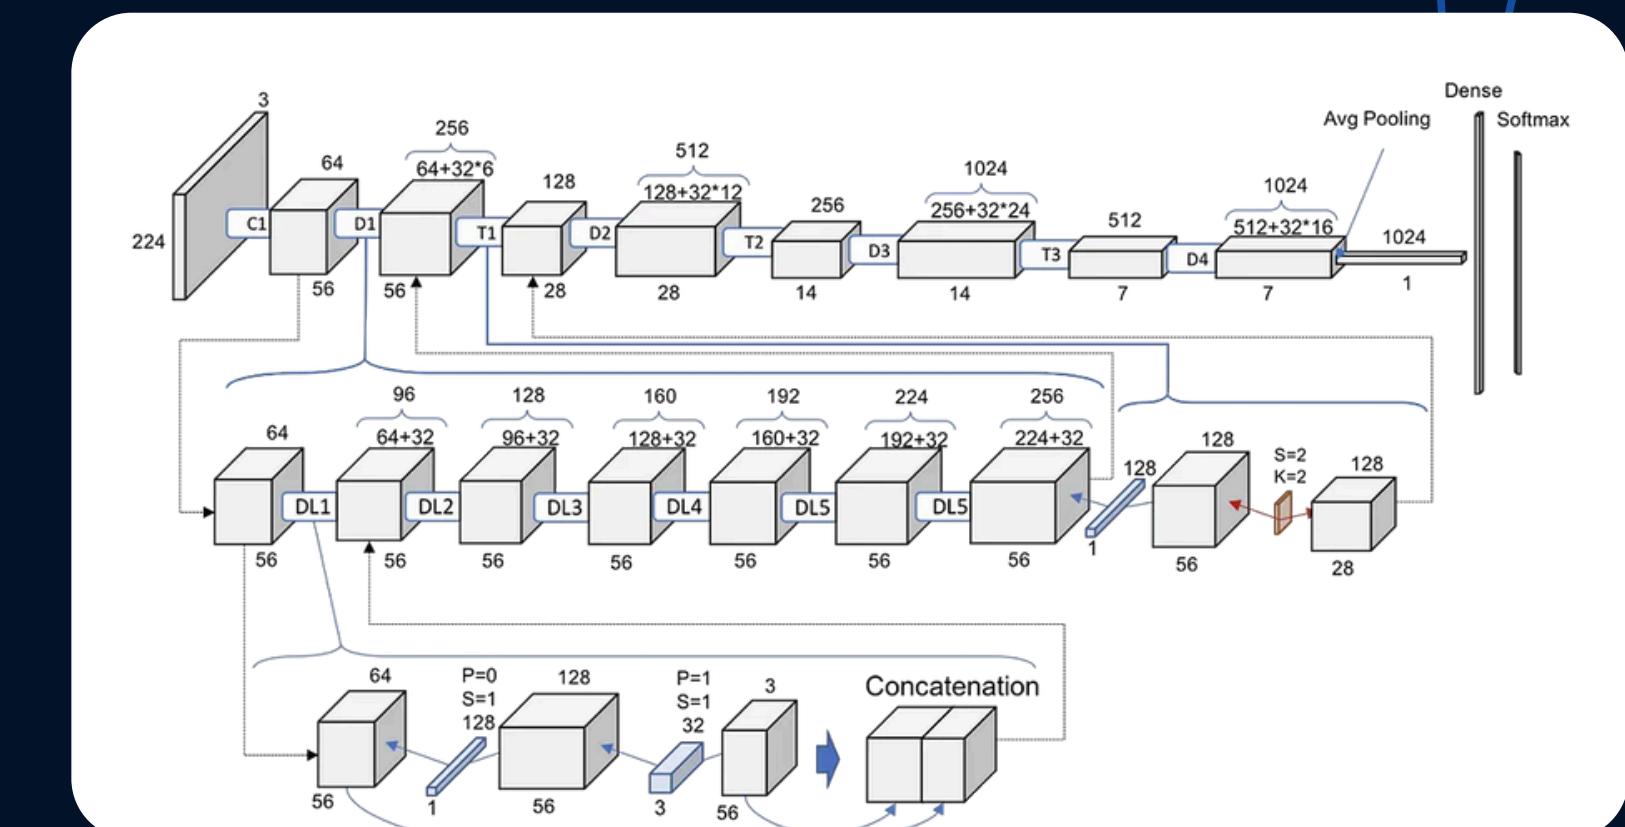
Klasik Mimariden Derin Rezidüel Yapıya (AlexNet - ResNet50)

PROJENİN İLK AŞAMASINDA, DERIN ÖĞRENME TARIHİNİN ÖNCÜSÜ OLAN ALEXNET İLE TEMEL BİR REFERANS NOKTASI OLUŞTURDUK. ANCAK MODEL DERİNLEŞTİKÇE ORTAYA ÇIKAN 'ÖĞRENME KAYBI' (VANISHING GRADIENT) SORUNUNU AŞMAK İÇİN RESNET50 MIMARISINE GEÇİŞ YAPTIK. RESNET'İN SUNDUĞU 'ARTIK BAĞLANTILAR' (RESIDUAL CONNECTIONS) TEKNOLOJİSİ, BILGINİN KATMANLAR ARASINDA KAYBOLMADAN ATLAMALI OLARAK İLETİLMESİNI SAĞLADI. BU SAYEDE, RÖNTGENLERDEKİ KARMAŞIK DOKULARI MODELİN ÇOK DAHA DERİN KATMANLARINDA BİLE BOZULMADAN İŞLEYEBİLDİK.



Standart Akıştan Yoğun Bilgi Ağına (ResNet18 - DenseNet121)

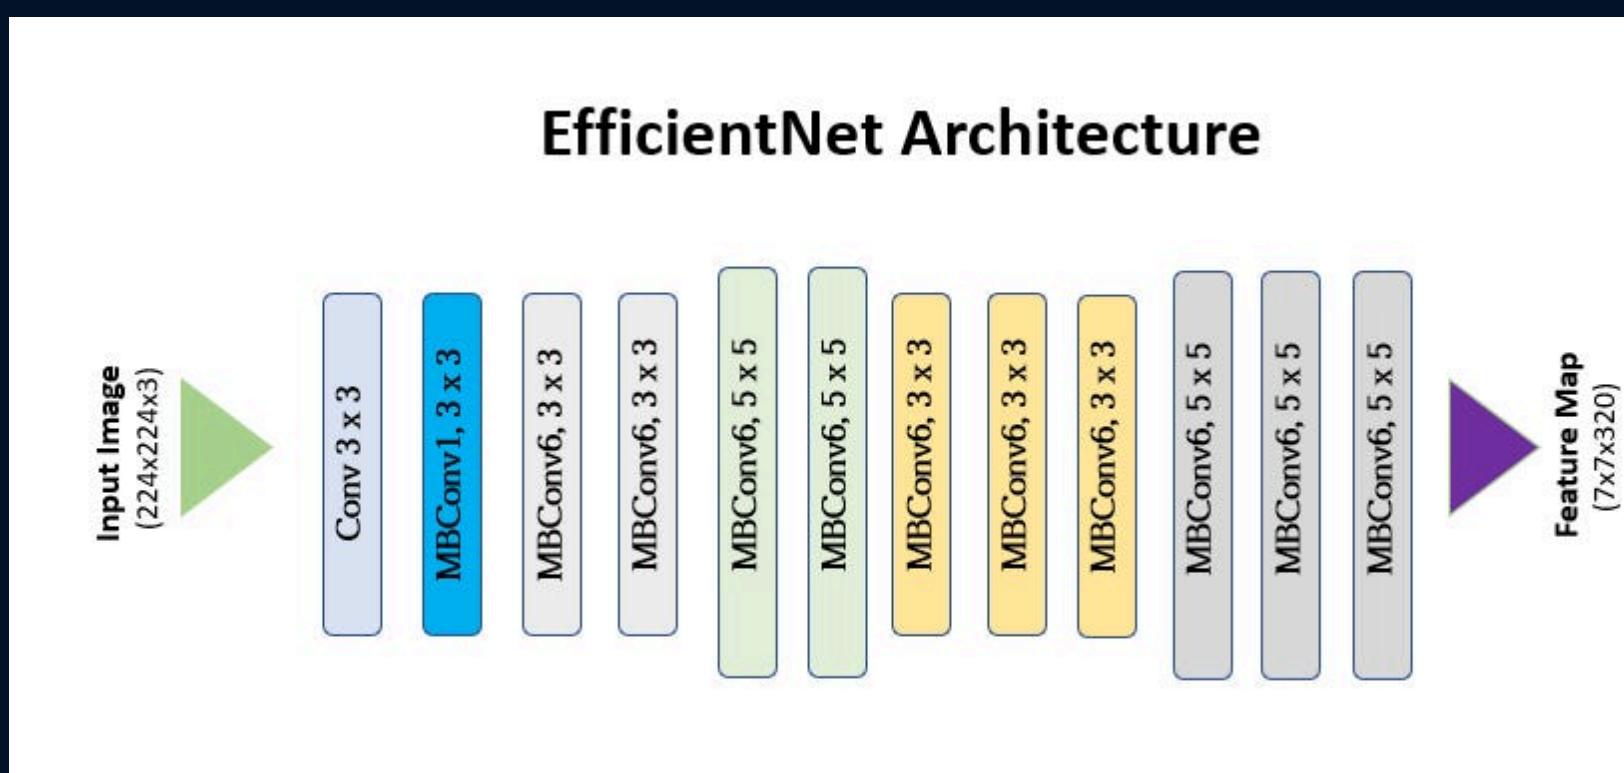
DIĞER KOLDA İSE STANDART BİR CNN YAPISI OLAN RESNET18 İLE VERİMLİLİK ODAKLı DENSENET121 MIMARISINI KIYASLADIK. DENSENET'İN EN BÜYÜK FARKI, HER KATMANIN KENDİNDEN ÖNCEKİ TÜM KATMANLARDAN DOĞRUDAN VERİ ALDIĞI 'YOĞUN BAĞLANTI' (DENSE CONNECTIVITY) YAPISIDIR. BU MIMARI, 'ÖZNİTELİK TEKRARI' (FEATURE REUSE) SAĞLAYARAK AĞIN HAFIZASINI GÜCLENDİRİR. BÖYLECE AKCIĞERDEKİ ÇOK İNCE DETAYLAR, AĞIN SONUNA KADAR TAŞINARAK TEŞHİS DOGRULUĞUNU MAKSIMIZE ETMİSTİR.



Verimlilik ve Hız Odaklı Modeller

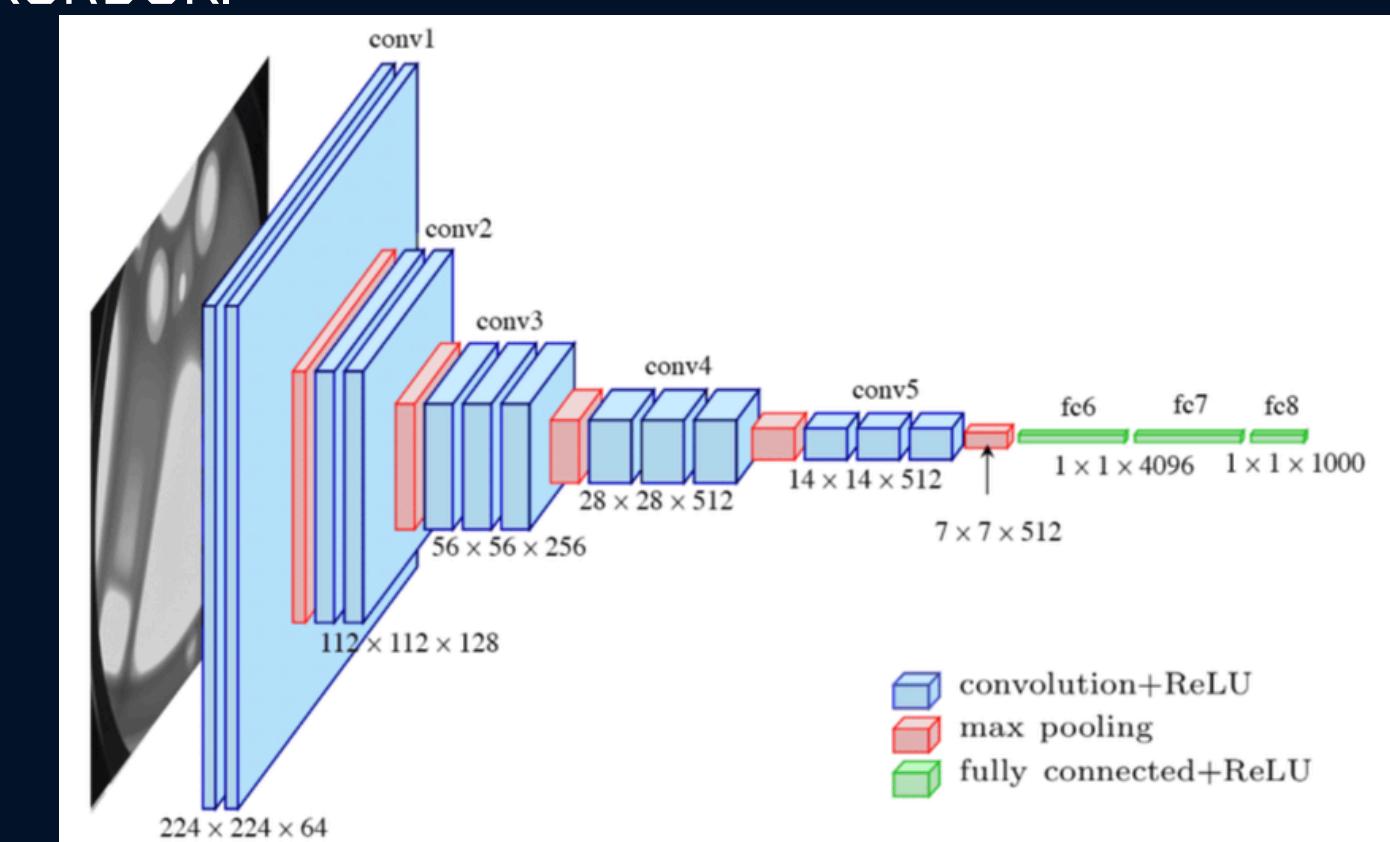
Klasik Yükten Akıllı Ölçeklendirmeye (VGG11 - EfficientNet-B0)

ECREEN'IN ÇALIŞMASINDA, DERİN ÖĞRENMENİN KLASİKLERİNDEN OLAN VGG11 İLE BAŞLADIK. ANCAK VGG'NIN PARAMETRE YOĞUNLUĞU, EĞİTİM HİZINI YAVAŞLATIYORDU. BUNA ÇÖZÜM OLARAK GOOGLE'IN GELİŞTİRDİĞİ EFFICIENTNET-BO MİMARISINE GEÇİŞ YAPTIK. EFFICIENTNET, AĞIN SADECE DERİNLİĞİNİ DEĞİL; GENİŞLİĞİNİ VE ÇÖZÜNÜRLÜĞÜNÜ DE DENGELİ BİR ŞEKLDE ARTIRAN 'COMPOUND SCALING' (BİLEŞİK ÖLÇEKLENDİRME) TEKNOLOJİSINI KULLANIR. BU SAYEDE, ÇOK DAHA AZ İŞLEM GÜCÜYLE VGG'DEN DAHA YÜKSEK BİR DOĞRULUK ELDE EDEREK KAYNAK VERİMLİLİĞİNİ KANITLADIK.



Hafiflikten Mobil Entegrasyona (SqueezeNet - MobileNetV2)

SUDENAZ'IN ODAK NOKTASI İSE MOBİL UYUMLULUK VE HİZDI. BAŞLANGIÇTA PARAMETRE TASARRUFU SAĞLAYAN SQUEEZENET İLE TEMEL BİR BAŞARI YAKALADIK. ANCAK GERÇEK ZAMANLI BİR MOBİL UYGULAMA HEDEFİ İÇİN MOBILENETV2 MİMARISINI TERCİH ETTİK. BU MODELİN KULLANDIĞI 'INVERTED RESIDUALS' (TERSİNE ÇEVRİLMİŞ ARTIKLAR) YAPISI, MODELİN HAFIZA YÜKÜNÜ MINIMIZE EDERKEN HİZINI MAKSİMIZE ETTİ. SONUÇ OLARAK, BİR CEP TELEFONUNDА BİLE SANİYELER İÇİNDE ÇALIŞABILECEK HAFİFLİKTE AMA TEŞHİS GÜCÜ YÜKSEK BİR YAPI KURDUK.



Performans Tablosu.

Model	Accuracy (%)	Precision (Macro Avg)	Recall (Macro Avg)	F1-Score (Macro Avg)
AlexNet (Mehmet - Base)	%84.25	0.85	0.81	0.82
ResNet50 (Mehmet - Adv)	%86.31	0.87	0.85	0.85
VGG11_BN (Ecren - Base)	%85.45	0.89	0.82	0.84
EfficientNet-B0 (Ecren - Adv)	%87.01	0.90	0.83	0.86
ResNet18 (Selen - Base)	%85.73	0.88	0.82	0.85
DenseNet121 (Selen - Adv)	%84.69	0.83	0.83	0.83
SqueezeNet (Sude - Base)	%84.17	0.84	0.80	0.82
MobileNetV2 (Sude - Adv)	%86.94	0.87	0.85	0.86

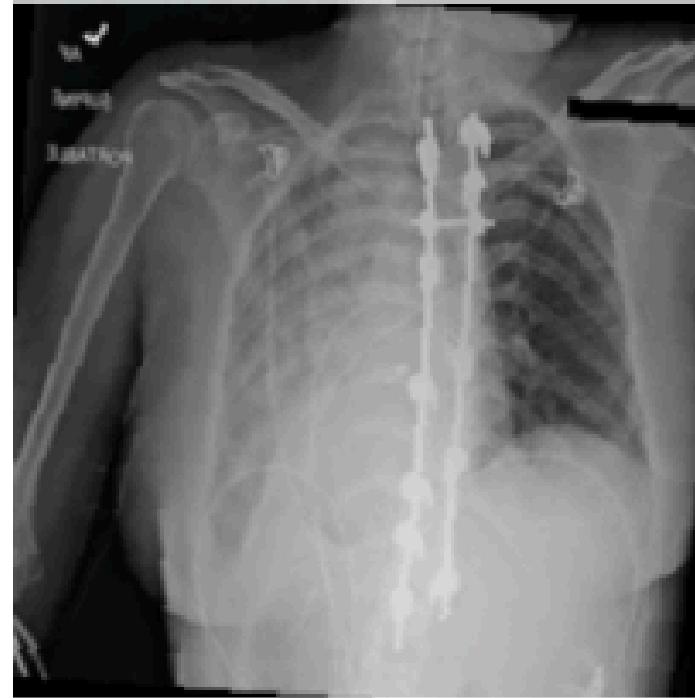
Model Nasıİ Karar Veriyor?

Ecren'in Modeli (VGG19) Tahmin Örnekleri

Gerçek: Lung_Opacity
Tahmin: Lung_Opacity



Gerçek: Lung_Opacity
Tahmin: Lung_Opacity



Gerçek: Normal
Tahmin: Normal



Gerçek: Normal
Tahmin: Normal



Gerçek: Normal
Tahmin: Normal



Gerçek: Normal
Tahmin: Lung_Opacity



Gerçek: Normal
Tahmin: Normal



Gerçek: Normal
Tahmin: Normal



Gerçek: Normal
Tahmin: Normal

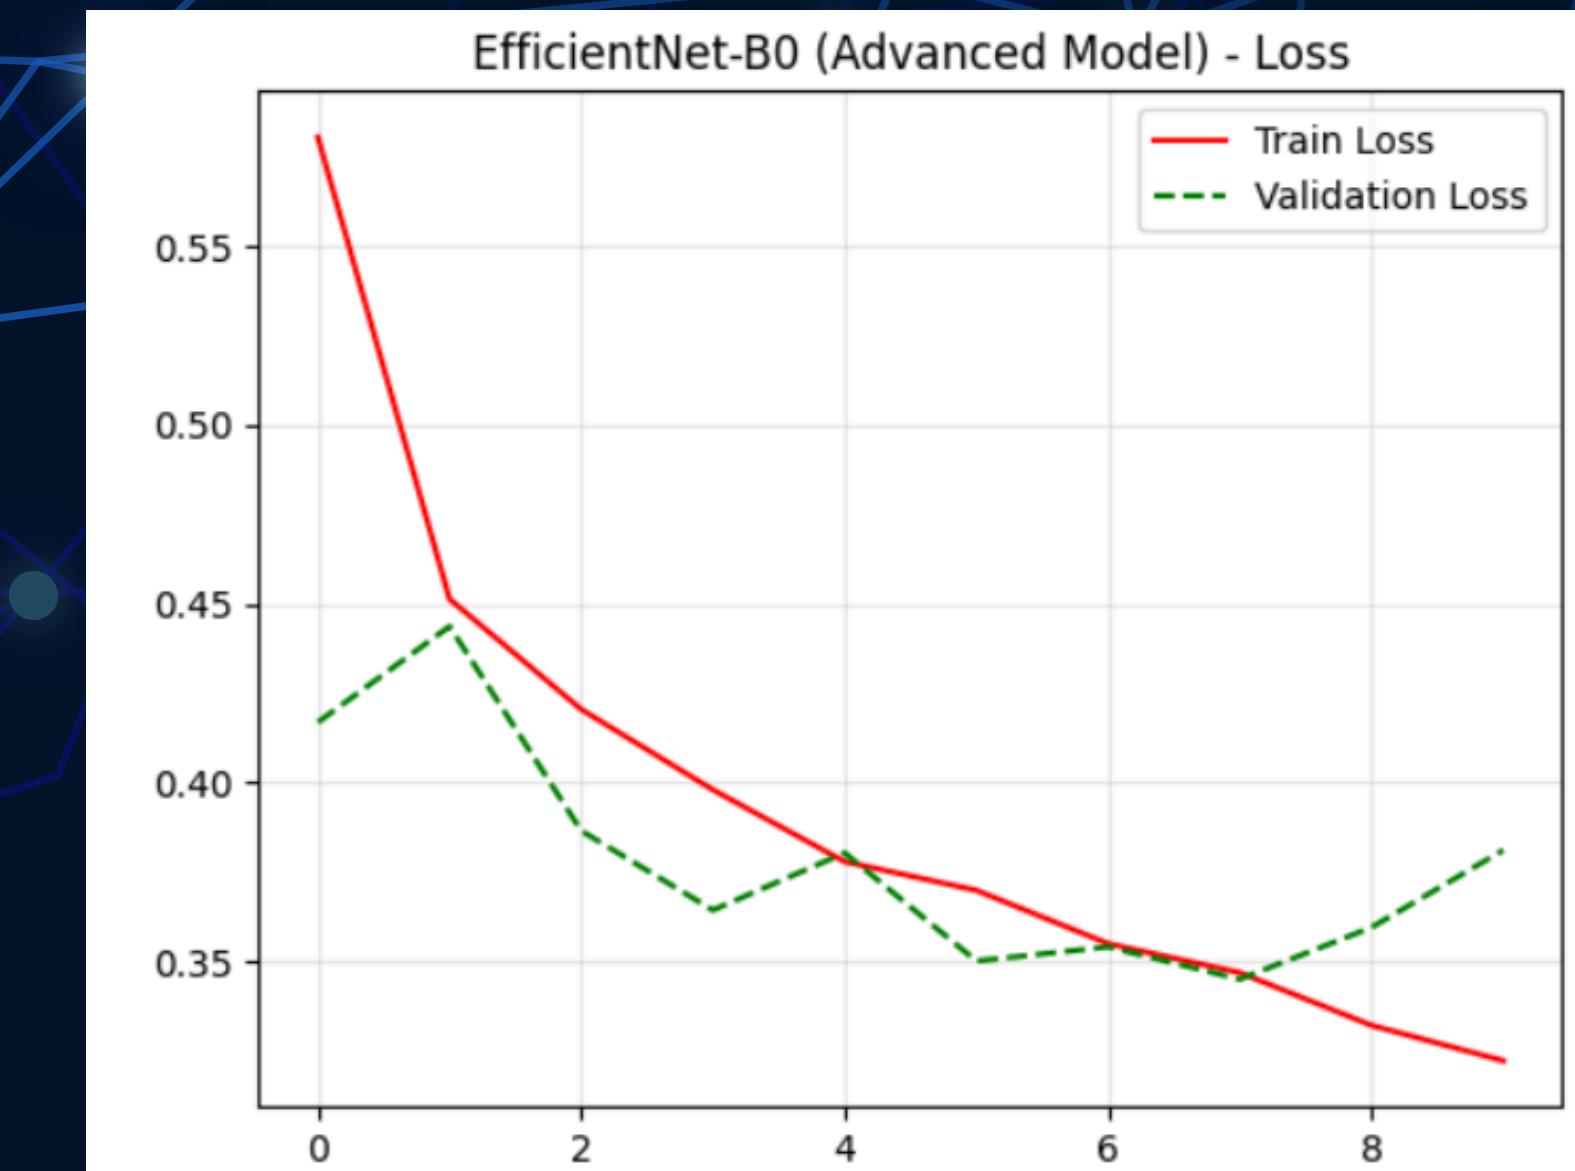
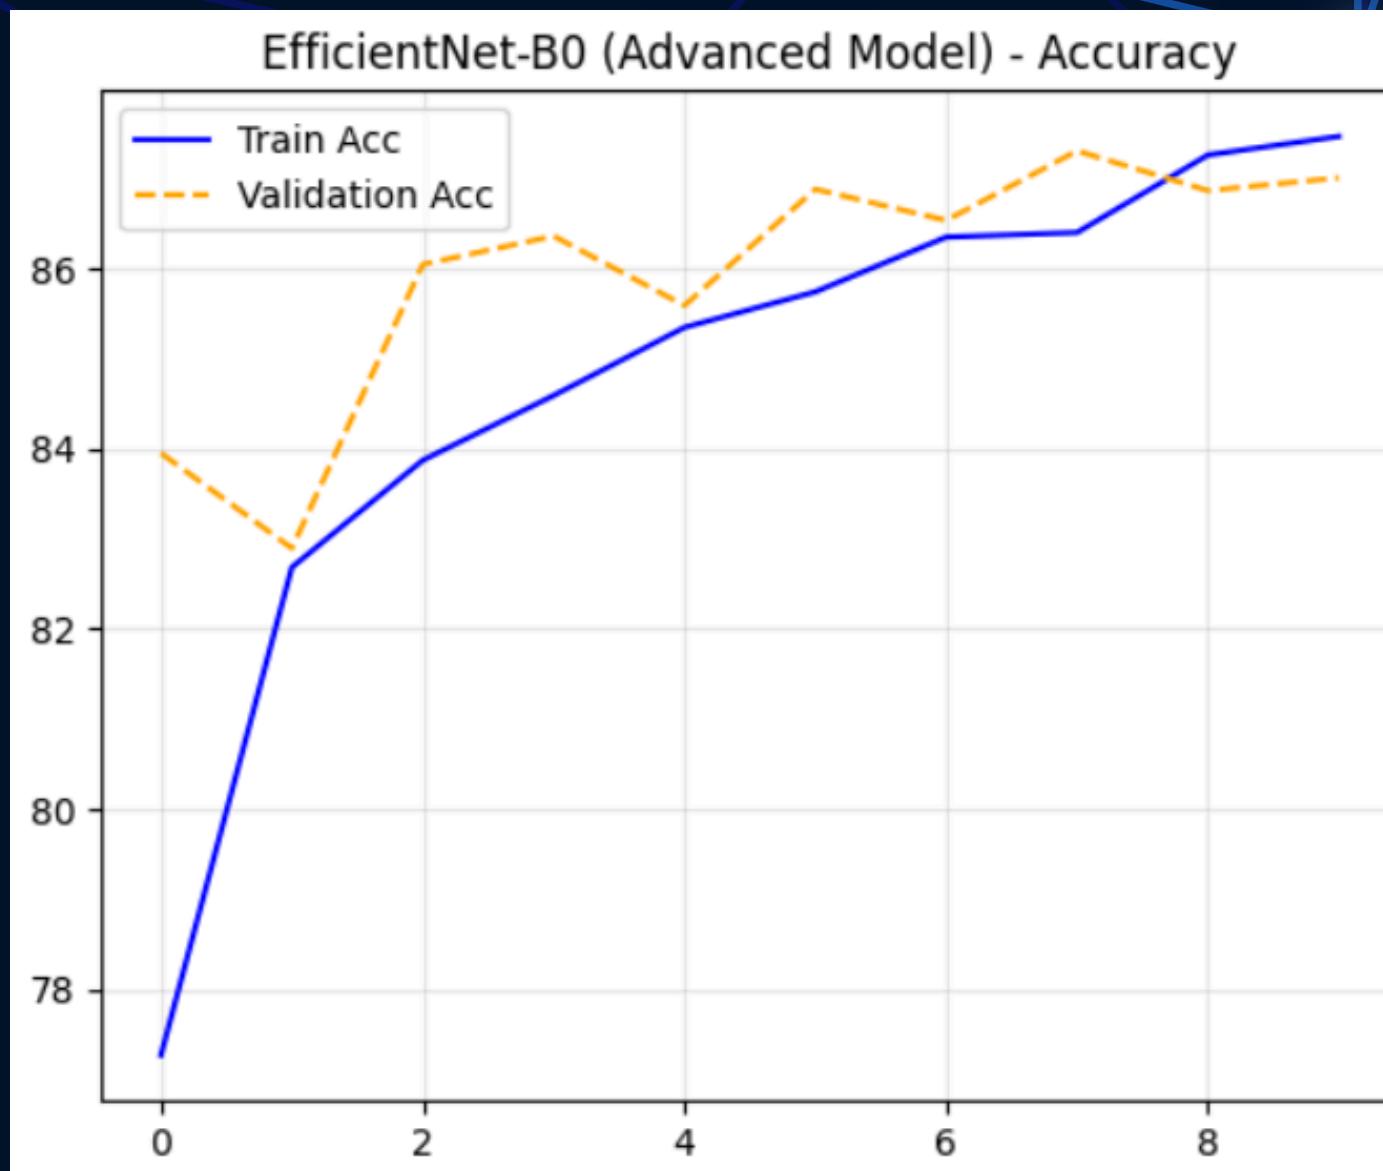


Gerçek: COVID
Tahmin: Normal



Eğitim Grafikleri

En iyi model olan EfficientNet-B0'ın Accuracy ve Loss Grafikleri



Grafikler incelendiğinde, modelin eğitim süreci boyunca hatasını (Loss) istikrarlı bir şekilde azalttığı ve doğruluk oranını (Accuracy) %87 seviyesine taşıdığı görülmektedir. Turuncu (Validation) çizgisinin Mavi (Train) çizgisini istikrarlı takibi, modelin sadece eğitim setindeki görüntüleri değil, gerçek dünyadaki farklı röntgen görüntülerini de doğru yorumlama kapasitesine ulaştığını gösteren en güçlü indikatördür.

Deneysel Çıkarımlar ve Proje Kazanımları

1. Transfer Learning'in Kritik Rolü

Proje başında sıfırdan bir ağ eğitmek yerine, ImageNet üzerinde önceden eğitilmiş ağırlıkları kullanmak (Transfer Learning), modelimizin öğrenme sürecini dramatik şekilde hızlandırdı. Bu strateji, özellikle sınırlı medikal veriyle çalışırken doğruluk oranımızı %10-15 bandında artırarak projenin başarıya ulaşmasındaki en büyük faktör oldu.

2. Veri Dengesizliğiyle Mücadele

Veri setindeki 'Viral Pneumonia' sınıfının sayısal azlığı (Imbalance), başlangıçta modelin bu vakaları gözden kaçırmasına neden oluyordu. Ancak uyguladığımız Veri Artırma (Data Augmentation) ve Tabakalı Bölümleme teknikleri sayesinde, modelin nadir görülen vakalara karşı duyarlığını artırarak dengeli ve güvenilir bir teşhis performansı yakaladık.

Deneysel Çıkarımlar ve Proje Kazanımları

3. Modern Mimarilerin Zaferi

Derin öğrenmede 'daha derin ağ her zaman daha iyidir' algısının aksine; EfficientNet ve MobileNet gibi modern mimarilerin, parametre verimliliği sayesinde eski nesil VGG modellerinden hem çok daha hızlı hem de daha başarılı olduğunu deneysel olarak kanıtladık. Bu durum, gelecekteki medikal projelerde 'verimliliğin' ön planda olması gerektiğini gösterdi.

4. Çok Yönlü Analiz ve Takım Çalışması

Proje boyunca 4 kişilik ekibimizle toplam 8 farklı mimariyi eş zamanlı test ederek, literatürdeki hemen hemen tüm yaklaşımları kapsayan geniş bir analiz gerçekleştirdik. Farklı stratejilerin (Hız odaklı vs. Derinlik odaklı) kıyaslanması, bize tek bir modele körük körüğe bağlanmadan 'En Optimum Çözümü' bulma yetkinliği kazandırdı.



BİZİ DİNLEDİĞİNİZ İÇİN TEŞEKKÜR EDERİZ